

다중 클래스 한국어 감성분석에서 클래스 불균형과 손실 스파이크 문제 해결을 위한 기법

박제윤^{1o*}, 양기수^{1*}, 박예원^{2*}, 이문기^{3*}, 이상원^{4*}, 임수연^{5*}, 조재훈^{6*}, 임희석^{1*}

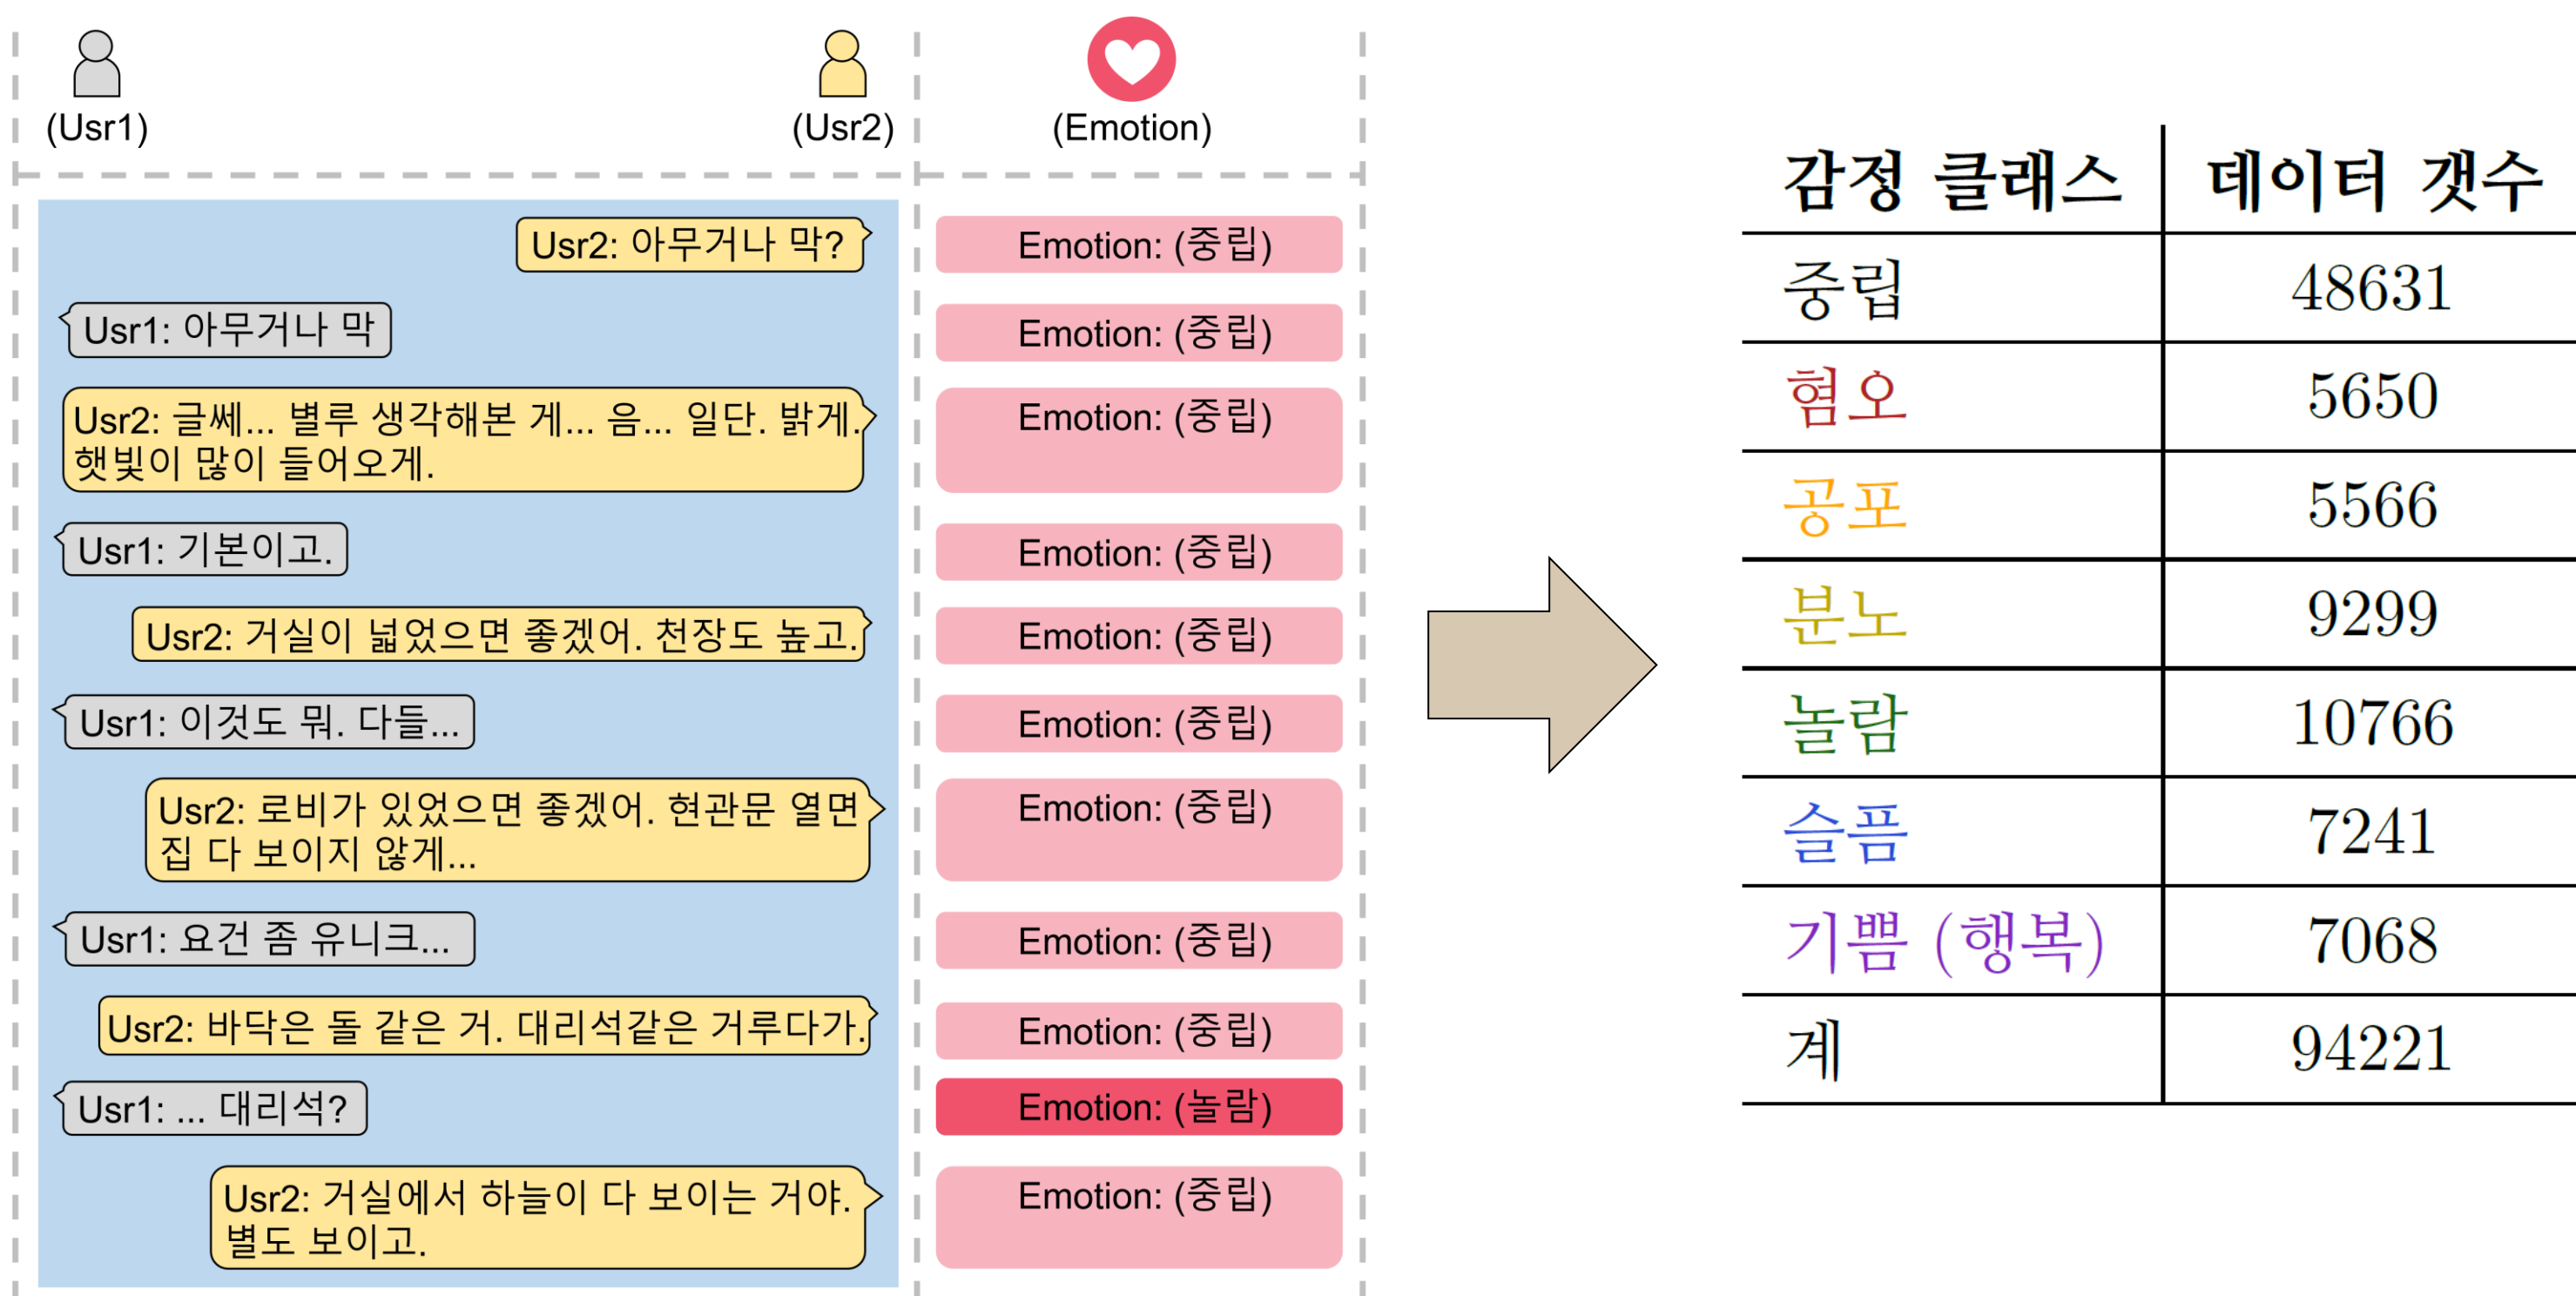
¹고려대학교, ²숙명여자대학교, ³㈜대륜이엔에스, ⁴인천대학교, ⁵한국과학기술연구원, ⁶연세대학교

서론

- ◆ **[필요성]** 다중클래스 감성분석은 상품평 분석을 통한 고객의 니즈분석 광고효과 분석, 영화평 분석, 그리고 풍부한 대화 시스템 응답 등 다양한 분야에 적용될 수 있음.
- ◆ **[기존 연구의 한계]** 한국어 감성분석에서 기존의 대부분의 연구는 실제 사용자의 감정을 긍정과 부정 두 개의 클래스 만으로 분류하는 것을 목표로 하기 때문에 현실 화자의 감정 정보를 정확하게 분석하기에 어려움이 있음.
- ◆ **[CONTRIBUTION]** 기존 연구들에서 많이 다루어지지 않은 한국어 다중클래스 감성분석과 여기에서 발생하는 문제점들을 해결하기 위한 방안들에 대해 논의하였음.
- ◆ 화자간의 대화 특성상 대부분의 데이터가 중립 정보를 가지는 클래스의 불균형 문제와 그로 인한 학습이 원활하게 되지 않는 문제를 해결하기 위해 기존에 분류에서 많이 쓰이는 Cross Entropy Loss에 클래스 수만큼 패널티를 주어 학습하였음.
- ◆ 또한 학습과정에서 연속적 대화 데이터셋과 단발성 대화 데이터셋을 합치고 무작위로 섞어서 데이터가 레이블에 순차적으로 학습되는 문제를 해결하였음.

데이터 및 모델

- ◆ **[데이터]** AI-hub에서 오픈한 다중클래스 감성분석 대화데이터를 사용함. 이 데이터는 전체 9만여 대화 세션들 중 중립이 절반 이상을 차지함.
- ◆ **[모델]** SKT에서 공개한 한국어에 적용 가능한 BERT를 활용함.



< 표1. 데이터 예시 >

실험

1 클래스 불균형 문제

- ◆ 기존 한국어 감성분석은 긍정, 부정 분류에 따른 Cross Entropy Loss (CE)를 사용함.
- ◆ 하지만 클래스가 불균형 문제가 있는 현재의 데이터에 CE를 사용 시 편향된 모델 파라미터를 학습하는 오류가 발생함.
- ◆ 우리는 클래스 수에 따른 패널티를 적용하기 위하여 Weighted Cross Entropy (WCE)를 사용하여 편향되지 않는 한국어 감성분석 모델을 구축함.

※ k : 각 클래스에 대응되는 숫자, y_k : 감정클래스, n_k : 각 클래스에 포함된 데이터 수

$$\tilde{H}_p(y_k) = -\frac{N}{A(k)} \sum_i^{n_k} y_k(x_i) \log p(x_i)$$

$$\text{where } N = \sum_j x_j \text{ and } A(k) = \sum y_k$$

<Weighted Cross Entropy>

2 손실스파이크(Loss Spikes)

- ◆ AI-hub 한국어 다중 클래스 데이터 사용 시 그림 3a와 같이 손실 함수 값이 매 epoch마다 튀는 손실 스파이크 (Loss Spikes) 문제가 발생함.
- ◆ 해당 문제를 해결하기 위해 데이터셋을 합치고 발화문장과 레이블 쌍을 메모리에 넣은 후 랜덤을 섞은 데이터를 일정 배치만큼 가져오도록 하였음.

- ◆ 그 결과 그림3b, 그림 4b처럼 손실함수의 감소 및 학습이 원활하게 완료됨




그림 3. (a) 손실 스파이크가 발생했을 때의 손실함수, (b) 손실 스파이크를 해결했을 때의 손실함수. 그림 4. (a) 손실 스파이크가 발생했을때의 성능, (b) 손실 스파이크를 해결했을때의 성능.

결과

Method	Micro F1
KoBERT + Unshuffled	0.008
KoBERT + Shuffled	71.560
Ours	76.560

< 표2. 경험적인 실험 결과 >

- ◆ 표2는 AI-hub 멀티클래스 대화 데이터셋에서의 실험 결과를 나타냄.
- ◆ 클래스 불균형에 대한 정확한 측정을 위해 F1 score에 클래스 불균형 정도가 반영된 Micro F1을 측정 지표로 사용하였음.
- ◆ 손실 함수의 값이 매 epoch마다 크게 튀는 현상인 손실 스파이크를 해결하지 못한 경우에는 전혀 학습이 진행되지 않았지만, 손실 스파이크를 해결한 모델에 대해서는 학습이 잘 되는 것을 볼 수 있었음.
- ◆ 손실 함수에 클래스 가중치를 주어 학습을 할 경우 더 높은 성능을 나타내는 것을 확인할 수 있었음.

결론

- ◆ 기존의 '긍정/부정', 두 클래스 분류만을 다루었던 한국어 감성분석에 대해 BERT 모델을 활용하여 7개의 다양한 클래스로 분류하는 방법을 제안함.
- ◆ 이 기법에서 발생하는 문제인 각 클래스간의 데이터셋 불균형의 문제를 Shuffle과 Weighted Cross Entropy를 활용하여 해결하고 감성분석의 성능을 향상시킴.
- ◆ 향후 연구로는 한국어에 적합한 이모지 추천을 통해 문자 위주의 비대면 소통시 비언어적 요소가 없는 환경을 어느정도 완화시킬 수 있을거라고 기대함.